

친구비 측정기 — OCR 재선정 보고서

항목	값
버전	v1.1
작성일	2026-08-26
상위 문서	친구비-측정기-서비스-기준-명세.md
대체 대상	AI-모델-선정-보고서.md 4장 (OCR 부분)
성격	조사 보고서. 확정 명세가 아니다

1. 왜 다시 하는가

이전 보고서는 월 100건 기준으로만 비용을 계산했다. 그 구간에서는 모든 후보가 무료 한도 안에 들어와서 "비용은 문제가 아니다, 품질로 고르면 된다"는 결론이 나왔다.

규모를 넣어 다시 계산하니 결론이 뒤집혔다.

월 분석	Vision (API)	CLOVA (API)	자체 — Cloud Run	자체 — VPS
100건	0원	0원	27,600원	9,800원
1,000건	8,400원	40,000원	27,600원	9,800원
3,000건	29,400원	140,000원	27,600원	9,800원
5,000건	50,400원	240,000원	27,600원	9,800원
20,000건	207,900원	990,000원	27,600원	9,800원

OCR 비용만. 분석당 이미지 5장 기준. backend/tools/cost_model.py 로 재계산할 수 있다.

LLM이 아니라 OCR이 비용을 지배한다. Groq 무료 티어는 월 15,000건까지 0원인데, OCR은 건당 과금이라 선형으로 오른다. 월 20,000건에서 CLOVA는 99만 원, Vision도 21만 원이다.

자체 호스팅은 어디에 띄우느냐로 갈린다

"자체 호스팅"은 로컬 PC에서 서비스를 돌린다는 뜻이 아니다. 클라우드 컨테이너 안에 OCR 모델을 넣어 API 호출을 대신한다는 뜻이다. 배포처는 여전히 클라우드다. 로컬 PC는 평가에만 쓴다.

그런데 어느 클라우드에 어떻게 띄우느냐로 비용이 세 배 갈린다.

방식	월 고정비	전환점	대가
Cloud Run 최소 인스턴스 1	27,600원	월 약 2,831건	스케일-투-제로 포기
저가 VPS	9,800원	월 약 1,141건	OS 패치·인증서·모니터링을 직접 진다

Cloud Run은 최소 인스턴스를 1로 두면 유휴 요금이 붙는다. 1 vCPU + 2GiB 기준 시간당 약 \$0.027이고, 무료 한도(vCPU 180,000초)는 상시 실행 한 달치의 7%밖에 덮지 못한다.

VPS는 훨씬 싸지만 지금까지 우리가 피해온 **서버 관리 부담**을 다시 지는 것이다. 기준 명세 8장이 "정적 호스팅 + 인스턴스가 0으로 내려가는 단일 서비스"를 택한 이유가 사라진다.

2. 후보 재정리

2.1 자격 요건은 그대로다

좌표를 반환하지 않는 엔진은 여전히 탈락이다. 화자 판별이 말풍선 좌우 여백에 의존하기 때문이다. 이건 비용과 무관한 조건이다.

여기에 이번 계산으로 조건이 하나 붙는다. **볼륨이 커질 때의 비용 곡선**을 함께 봐야 한다.

2.2 비교표

후보	좌표	한국어	100건/월	5,000건/월	스케일-투-제로	서버 관리
Google Cloud Vision	제공	상위권	0원	50,400원	유지	없음
Naver CLOVA OCR	제공	최상위 (97%+)	0원	240,000원	유지	없음
Upstage Document OCR	제공	국내 특화	페이지당 \$0.01	약 700,000원	유지	없음
RapidOCR (자체)	제공	모델 교체 필요	9,800~27,600원	9,800~27,600원	포기	있음
EasyOCR (자체)	제공	기본 지원	9,800~27,600원 +	9,800~27,600원 +	포기	있음
PaddleOCR (자체)	제공	별도 모델	9,800~27,600원 +	9,800~27,600원 +	포기	있음

자체 호스팅의 폭은 배포처 차이다. 낮은 쪽이 VPS, 높은 쪽이 Cloud Run 상시 실행이다.

Upstage는 페이지당 \$0.01로 Vision의 약 7배다. 국내 문서 특화가 강점이지만 우리는 정형 문서가 아니라 채팅 캡처를 다루므로 그 강점이 살지 않는다. **후보에서 제외한다.**

2.3 자체 호스팅의 진짜 비용

위 고정비는 **하한선**이다. 실제로는 세 가지가 더 붙는다.

- **스케일-투-제로를 포기한다.** 기준 명세 6장이 전제한 배포 형태와 충돌한다. 요청이 없어도 과금된다.
- **컨테이너가 무거워진다.** 모델과 런타임이 들어가 콜드 스타트와 메모리 요구가 오른다. 이미 동시성이 메모리에 묶여 있는데(동시 20건에 446MB) 여기서 더 조여진다.
- **모델 관리 부담.** 한국어 인식 모델을 직접 받아 넣고, 사전 파일을 맞추고, 버전을 관리해야 한다.

즉 **전환점은 비용만 본 숫자**이고, 운영 부담을 넣으면 더 뒤로 밀린다. 특히 VPS 쪽 1,141건은 "서버를 직접 관리할 각오가 되어 있다"는 전제 위에서만 성립한다.

3. 권고

단계를 나눈다. 한 번에 정하지 않는다.

단계	월 분석	OCR	이유
초기	~1,000건	Google Cloud Vision	무료 한도가 덮고, 좌표가 확실하며, 스케일-투-제로를 유지한다
성장	1,000~3,000건	Vision 유지	Cloud Run 상시 실행(27,600원)보다 여전히 싸다. 운영 단순함까지 감안하면 비교가 안 된다
확대	3,000~10,000건	Vision 유지 또는 자체 호스팅 검토	이 구간에서 처음으로 자체 호스팅이 싸진다. 다만 차이가 크지 않다
대규모	10,000건~	자체 호스팅	Vision 10만 원 대 자체 3만 원. 이때는 차이가 분명하다

초기 판단은 **이전 보고서와 같다**. 바뀐 것은 "언제 갈아탈지"이고, 그 시점이 생각보다 **뒤에 있다**는 것이다.

CLOVA는 권고에서 뺀다. 한국어 인쇄체 정확도가 가장 높다는 점은 여전하지만, 비용이 Vision의 5배이고 우리가 읽는 것은 인쇄 문서가 아니라 **깨끗한 화면 렌더링 텍스트**다. Vision으로도 충분할 가능성이 높다. 실측에서 Vision이 부족할 때만 다시 꺼낸다.

4. 이 환경에서 성능평가가 가능한가

4.1 결론: 가능하다. 다만 조건이 있다

API 키 없이도 **자체 호스팅 후보는 지금 평가할 수 있다**. 그리고 자체 호스팅이 장기 답이 될 가능성이 높아졌으므로, 이 평가는 하는 편이 낫다.

4.2 하드웨어

측정한 값이다.

항목	값	판정
CPU	14코어 / 20스레드	충분
RAM	32 GB (가용 16 GB)	충분
GPU	NVIDIA RTX 4060 Ti 8GB	충분. CUDA 가속 가능
디스크	556 GB 여유	충분
Python	3.10.2 (venv 구성됨)	충분

GPU가 있다는 점이 중요하다. EasyOCR은 CPU에서 페이지당 2.5~3초가 걸리는데 GPU를 쓰면 크게 줄어든다. 자체 호스팅 후보를 제대로 재보려면 GPU가 사실상 필요하고, 이 환경에는 있다.

4.3 이미 확인한 것

RapidOCR(ONNX 기반, 약 15MB 모델)을 설치해 합성 캡처로 돌려봤다.

지표	결과
장당 처리 시간	0.89초 (CPU)
텍스트 인식률	0%
화자 판별 정확도	대조된 블록 28개 중 28개 정답 (100%)
Parser 통과	실패 (<code>GROUP_CHAT_DETECTED</code>)

텍스트 인식률 0%의 원인을 찾았다. RapidOCR 기본 패키지에는 중국어·영어 모델(`ch_PP-OCRv4_rec`)만 들어 있다. 한글 말풍선을 통째로 놓치고 숫자와 시각만 읽었다.

인식 결과 예시

0.98	'2026825'	<- 날짜에서 숫자만
0.99	'9:13'	<- 시각은 정확
0.64	'???'	<- 한글 말풍선은 깨짐

이것이 **한국어 인식 모델을 반드시 별도로 넣어야 한다는** 실증이다.

4.4 그럼에도 의미 있는 결과가 하나 나왔다

탐지(detection) 단계는 정확했다. 말풍선 위치를 제대로 찾았고, 그 좌표로 화자를 판별한 결과가 **대조된 블록 전부 정답**이었다.

한글을 못 읽는 상태에서도 좌표는 정확했다는 뜻이고, 이는 **우리의 좌우 여백 판별 방식이 실제 카카오톡 레이아웃에서 작동한다**는 첫 증거다. 지금까지는 우리가 만든 합성 픽스처 안에서만 확인했었다.

다만 대조된 블록이 113개 중 28개뿐이었다. 나머지는 시각 라벨과 날짜 구분선이라 정답 말풍선에 속하지 않는다. 표본이 작으므로 확정적 근거로 삼지 않는다.

4.5 평가에 필요한 것

후보	필요한 것	설치 규모	비고
RapidOCR + 한국어 모델	<code>korean_PP-OCRv5_mobile_rec.onnx</code> + <code>ppocrv5_korean_dict.txt</code>	약 20 MB	가장 가볍다. 모델 경로만 지정하면 교체된다
EasyOCR	<code>pip install easyocr</code> (torch 포함)	약 500 MB	한국어 기본 지원. GPU 권장
PaddleOCR	<code>paddlepaddle</code> + <code>korean_PP-OCRv3_rec</code>	수백 MB	v4에는 한국어 모델이 없고 v3 또는 v5를 써야 한다
Google Vision	API 키	0	자체 호스팅과 비교하려면 필요
Naver CLOVA	API 키 + 도메인 등록	0	신청 절차가 있다

가장 적은 노력으로 가장 많이 아는 방법은 RapidOCR에 한국어 모델만 있는 것이다. 이미 설치와 연동 코드가 되어 있고, 모델 파일 두 개를 받아 경로를 지정하면 된다. 20MB 추가로 자체 호스팅 후보의 실력을 알 수 있다.

4.6 준비해 둔 도구

평가에 필요한 것은 모두 만들어 두었다. 명령만 실행하면 된다.

```
# 1. 정답이 딸린 합성 캡처를 만든다
python tools/render_kakao.py --out synth --count 6 --turns 14

# 2. OCR 엔진을 채점한다
python tools/benchmark_ocr.py --images synth --engine rapid --out fx/rapid.json

# 3. 실제 캡처가 생기면 같은 도구로 쟀다
python tools/evaluate_ocr.py --images caps/대화01 --engine google_vision --key $KEY
```

`render_kakao.py` 는 카카오톡 화면을 실제로 그린다. 밝은 테마, 노란 말풍선, 프로필 자리, 시각 라벨, 날짜 구분선까지 재현한다. **우리가 그렸으므로 어느 메시지가 누구 것인지 안다.** 그래서 이전 보고서가 "자동으로 쟀 수 없다"고 했던 화자 판별 정확도를 숫자로 낸다.

4.7 합성 캡처의 한계

정직하게 적는다. 합성 캡처에서 잘 나온다고 실제에서도 잘 나온다는 보장이 없다.

실제 캡처에는 없는 것이 합성에는 없다.

- JPEG 압축 노이즈, 스크린샷 리사이즈로 인한 흐릿함
- 실제 프로필 사진 (지금은 회색 원)
- 읽음 표시 숫자, 이모티콘, 사진 썸네일

- 기기마다 다른 폰트 두께와 다크 모드
- 손가락으로 가린 영역, 잘린 말풍선

합성 캡처 점수는 상한선에 가깝다. 여기서도 못 하면 실제에서는 확실히 못 한다. 반대는 성립하지 않는다.

그래서 합성 평가는 **후보를 걸러내는 용도**이고, 최종 판단은 실제 캡처로 해야 한다.

5. 권고하는 순서

1. RapidOCR에 한국어 모델을 얹어 합성 캡처로 채점 [키 불필요]
-> 텍스트 인식률과 화자 판별 정확도를 본다
-> 여기서 부족하면 자체 호스팅 후보를 접는다
2. 통과하면 EasyOCR도 같은 캡처로 채점 [키 불필요]
-> 두 후보 중 나은 쪽을 고른다
3. Google Vision을 같은 캡처로 채점 [키 필요]
-> 자체 호스팅과 클라우드의 실력 차를 본다
4. 실제 카카오톡 캡처 20세트로 상위 2개를 재확인 [실제 캡처 필요]
-> 최종 결정
5. 결정 후 문서 갱신
-> 이 보고서, AI-모델-선정-보고서 4장,
운영-보안-법적고지-명세 4.3의 제3자 제공 목록

1단계와 2단계는 **지금 바로 할 수 있다**. 3단계는 무료 키로 가능하다. 4단계만 실제 대화가 필요하다.

6. 미확인 항목

- 한국어 모델을 얹은 RapidOCR의 실제 인식률. 모델을 받아 돌려봐야 안다.
- Vision의 카카오톡 캡처 정확도. 문서 OCR 벤치마크는 있지만 채팅 캡처 사례는 확인하지 못했다.
- 자체 호스팅 시 컨테이너 크기와 콜드 스타트 시간. 동시성 예산에 직접 영향을 준다. 위 비용표는 1 vCPU + 2GiB를 가정했는데, 모델이 더 무거우면 고정비가 오른다.
- VPS 운영 부담의 실제 크기. 월 9,800원이라는 숫자에는 사람 시간이 빠져 있다.
- CLOVA 무료 한도. 자료마다 월 1,000건과 5,000건으로 엇갈린다.
- Upstage 무료 크레딧의 현재 조건. 이벤트성이라 시점에 따라 다르다.

7. 이번 조사에서 바뀐 판단

항목	이전	이번
비용의 지배 요인	LLM	OCR
자체 호스팅 전환점	월 2,000건 (근거 없음)	Cloud Run 2,831건 / VPS 1,141건
CLOVA 위치	2순위 대안	후보에서 내림 (Vision의 5배)
자체 호스팅 시점	"볼륨이 커진 뒤"	평가는 지금, 전환은 월 3,000건 이후
자체 호스팅의 뜻	불명확했음	클라우드 컨테이너에 모델 내장. 로컬 PC가 아니다
평가 가능 시점	API 키 확보 후	일부는 지금 가능

8. 개정 이력

버전	날짜	내용
v1.1	2026-08-26	자체 호스팅 비용을 배포처별로 분리. 이전 판에서 VPS 요금을 Cloud Run 배포에 적용한 오류를 정정
v1.0	2026-08-26	비용 모델 재계산에 따른 OCR 재선정. 로컬 평가 가능성 확인

참고 자료

- [Cloud Vision API 가격](#)
- [Cloud Run 가격](#)
- [PaddlePaddle/korean_PP-OCRv5_mobile_rec](#)
- [PaddlePaddle/korean_PP-OCRv3_mobile_rec](#)
- [RapidOCR Custom Models](#)
- [EasyOCR](#)
- [Upstage API 가격](#)
- [CLOVA OCR — NAVER Cloud Platform](#)